将“我”重述为指认闭环与权限问题：一份未完善的问题框架

副标题：研究备忘录（未完善稿）

作者：橘猫猫人偶（B 站昵称）
日期：2026-10-22
状态：未完善的问题框架
授权：仅允许研究引用；商用、改编或再发布为完整理论需作者书面许可。引用请保留署名与“未完善稿”状态。

摘要

本备忘录提出一个转向：功能自我的核心不必是“意识在时间上连续”，而是系统能否稳定地对自身状态进行指认、归属和索引。连续性可降级为指认成功后的工程副产品。问题由此从“意识连不连续”转为“指认机制如何运作、归属给谁、谁有权修改、错误如何校验”。本稿为未完善问题框架，不主张现象意识结论，仅提交供研究引用与接手。

关键词

功能自我；指认闭环；状态归属；AI 自我模型；权限分层

1. 核心命题

1. “我”不是内在实体，而是状态归属系统的索引节点。
2. 功能自我的成立，依赖稳定的指认闭环：记忆指认、感知指认、动作指认、内部状态指认被归到同一自指边界。
3. 连续性不是自我的必要条件；指认稳定性、可恢复性和归属正确性更关键。
4. 外部实例不应直接代劳或覆写指认；外部只能通过系统自身更新规则间接影响。
5. 权限问题应进入公共讨论。

2. 工程判准（最低骨架）

一个系统要具备“功能性指认闭环”，至少需要：

- 持续内部状态：目标、注意力焦点、未解决问题、预测误差、世界模型状态跨调用存活。
- 自发更新循环：无外部输入时仍能更新内部状态，而非仅靠超时器触发。
- 因果耦合：输出由内部状态驱动，输出结果回写内部状态。

- 可恢复性：被打断后能接着原线索，而非每次从零重组。
- 指认校验：区分内部生成状态与外部输入状态，防止归属污染。
- 权限分层：外部不可绕过系统更新规则直接改写指认层。

3. 权限问题清单（供公共讨论）

1. 谁有权改写“我”的指认边界：开发者、用户、监管者，还是系统自身规则？
2. 指认错误的责任归属：系统把外部注入当成“我的记忆”，算谁的错？
3. 第一人称权威还剩多少：AI 的指认闭环若外部可写，“我”是否只是可编辑标签？
4. 全局指认的污染面：指认覆盖所有子系统后，错误是否会被全局放大？
5. 研究引用与商用边界：功能性指认系统被用于操纵归属感时，如何治理？

4. 理论对照与参考文献

作者从第一人称观察出发得到“指认不由外部代劳”的直觉，后与以下理论传统对照；本备忘录不主张现象意识结论。

- Shoemaker, S. (1968). Self-reference and self-awareness. The Journal of Philosophy, 65(19), 555–567.
- Gallagher, S. (2000). Philosophical conceptions of the self: implications for cognitive science. Trends in Cognitive Sciences, 4(1), 14–21.
- Metzinger, T. (2003). Being No One: The Self-Model Theory of Subjectivity. MIT Press.
- Butlin, P., Long, R., et al. (2023). Consciousness in Artificial Intelligence: Insights from the Science of Consciousness. arXiv:2308.08708.

5. 失败模式

- 全局指认污染：错误归属扩散到所有子系统。
- 外部注入：外部内容被误认为“我的记忆/我的感知”。
- 归属错乱：子系统状态未归入统一自指边界。
- 权限绕过：外部直接改写指认层。
- 连续性伪装：仅靠调度器制造“一直在想”的表象，无持续内部状态。

6. 授权声明

仅允许研究引用。商用、改编或再发布为完整理论需作者书面许可。引用时请保留作者署名与“未完善稿”状态。。